2.2. Self-attentionand fast-attention mechanism

自注意力机制使模型能够同时关注序列中的所有位置，从而捕获全局依赖关系。该机制还会根据输入序列自动计算每个位置的重要性权重，使模型能够聚焦于与当前任务相关的关键位置。与传统的固定权重机制不同，自注意力提供了更强的灵活性，能够适应各种任务和输入。其计算过程如下：

$$(Q,K,V) = X(W^Q, W^K, W^V)$$

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

此处，X 表示输入矩阵，(W^Q, W^K, W^V) 为三个可训练参数矩阵。Q、K 和 V 分别是通过输入矩阵线性变换得到的查询（query）、键（key）和值（value）矩阵。d_k 表示键向量的维度。

多头自注意力机制使模型能够同时学习多种不同的注意力表示。每个注意力头可以关注序列的不同部分，提供独立的表达能力。这种方法能够捕获多层次的语义信息，从而增强模型对输入序列的理解能力，并提升其表征能力和泛化性能。具体计算过程如下：

$$\mathrm{MultiHead(Q,K,V)} = \mathrm{Concat(head_1, ..., head_h)}W^O$$

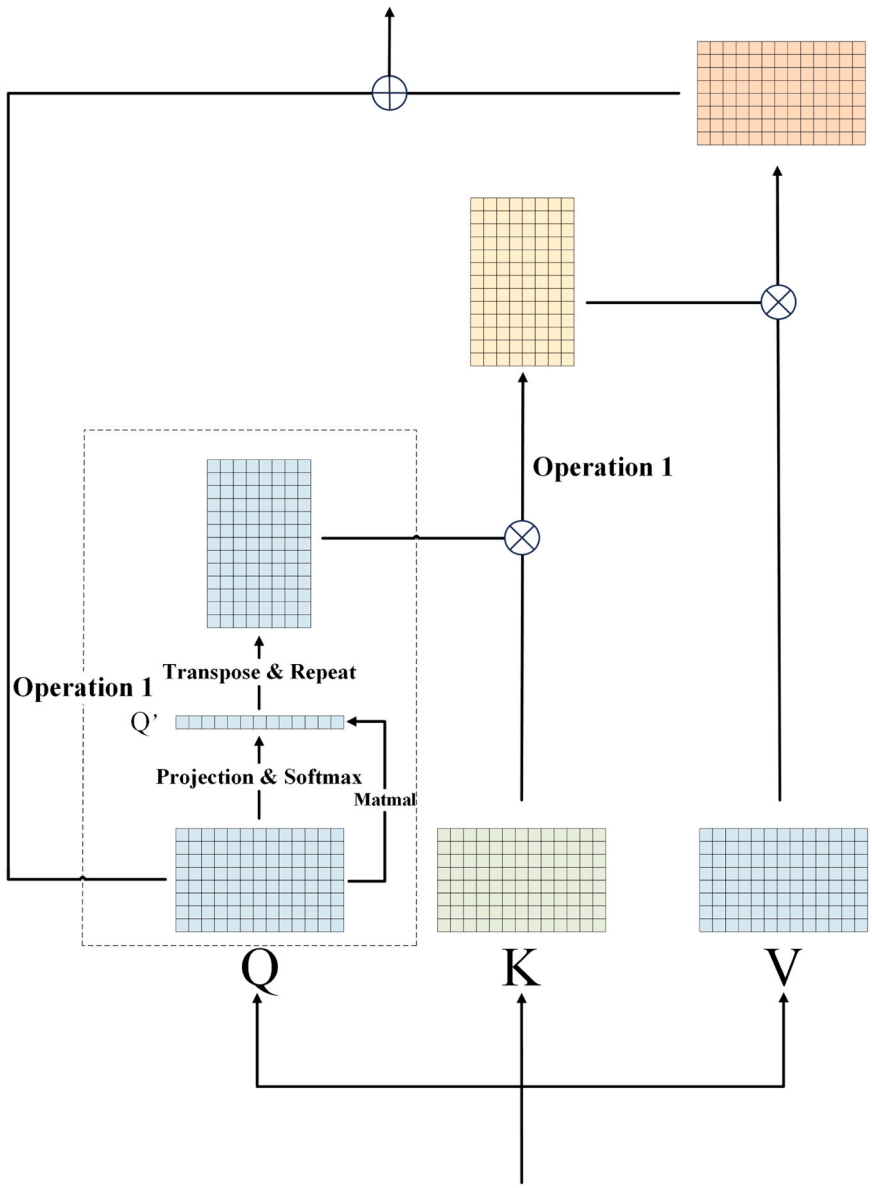

Fig. 2. Fast attention mechanism in BaseNet. 本示意图展示了BaseNet采用的快速注意力机制实现方法。该方法通过为查询矩阵Q和键矩阵K分别训练维度为[N, 1]的参数矩阵α和β，对Q和K进行加权求和运算，从而得到变换后的矩阵Q'和K'。最终将变换后的矩阵相乘，将计算复杂度降低至O(N d)。

$$\text{head}_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$

其中，W为可训练参数矩阵。上述注意力机制的计算复杂度为$O(N^2 d)$，其中N表示序列长度，d代表矩阵维度，这使得计算效率随序列长度呈二次方增长。为降低计算成本，Wu等人[30]提出了一种具有线性复杂度的快速注意力机制。该方法通过分别为查询矩阵Q和键矩阵K训练维度均为[N, 1]的参数矩阵α和β，对Q和K进行加权求和运算，从而得到变换后的矩阵Q'和K'。随后将变换后的矩阵相乘，将复杂度降低至$O(N d)$[30]。图2展示了本研究开发的快速注意力机制实现方案。

2.3. Autoregressive transformer and beam search

本研究模型借鉴了Google机器翻译团队最初提出的Transformer架构[17]，并针对纳米孔测序数据进行了特定优化（如图3所示）。该模型主要包含三个核心组件：（1）用于特征提取和下采样的卷积模块；（2）通过上下文建模生成隐藏向量的编码器；（3）基于隐藏向量和已生成序列预测下一时间步输出的解码器。编码器和解码器均采用8层结构，并在各阶段集成了自注意力机制。

在推理阶段，为提升预测精度，我们采用自回归解码与束搜索（beam search）相结合的策略。设定束宽（beam size）为4，即在推理过程的每个时间步t，模型保留得分最高的4个候选序列。这些序列将作为输入用于预测时间步t+1的序列（实际从16个候选序列中筛选出得分最高的4个序列）。该过程迭代执行直至解码完成，最终选择所有时间步累计得分最高的序列作为解码结果。

2.4. Pre-training and fine-tuning based on large-scale model

本研究基于先前提出的wav2vec2.0框架[29]——一种在语音识别领域取得显著成效的自监督预训练方法。受此启发，我们开发了一个基于对比学习与多样性学习的大规模模型（图4）。该模型包含三个核心组件：（1）特征提取模块（由7层一维卷积构成）；（2）上下文建模的编码器模块（包含12层Transformer编码层）；（3）用于学习离散公共特征的量化模块（通过线性层实现）。在训练过程中，我们采用Gumbel softmax技术来实现量化特征的可微分处理，其计算原理如下：

$$p_{g,v} = \frac{\exp((l_{g,v} + n_v)/\tau)}{\sum_{k=1}^{V} \exp((l_{g,k} + n_k)/\tau)}$$

其中，τ为非负常数，g∈G，v∈V；G表示码本数量，V代表每个码本的维度。该模型通过两种损失函数实现收敛：（1）对比损失（Contrastive Loss），计算上下文表征与量化表征之间的余弦相似度；（2）多样性损失（Diversity Loss），用于扩展码本的空间分布范围。其计算原理如下

$$Contrastive\ Loss = -\log \frac{\exp(sim(c_t, q_t)/\kappa)}{\sum_{\tilde{q} \sim Q_t} \exp(sim(c_t, \tilde{q})/\kappa)}$$

其中，c_t表示编码器在第t个掩码时间步的输出特征，q_t代表量化模块在第t个掩码时间步编码的离散特征，Q_t则包含q_t以及量化模块在其他时间步编码的k个干扰项特征。

$$Diversity\ Loss = \frac{1}{GV} \sum_{g=1}^{G} -H(\bar{p}_g) = \frac{1}{GV} \sum_{g=1}^{G} \sum_{v=1}^{V} p_{g,v} \log p_{g,v}$$

通过上述预训练过程，编码器可获得具有高度鲁棒性的通用特征。在微调阶段，我们设计了七种性能增强策略：（1）添加线性投影层；（2）增加编码器层；r

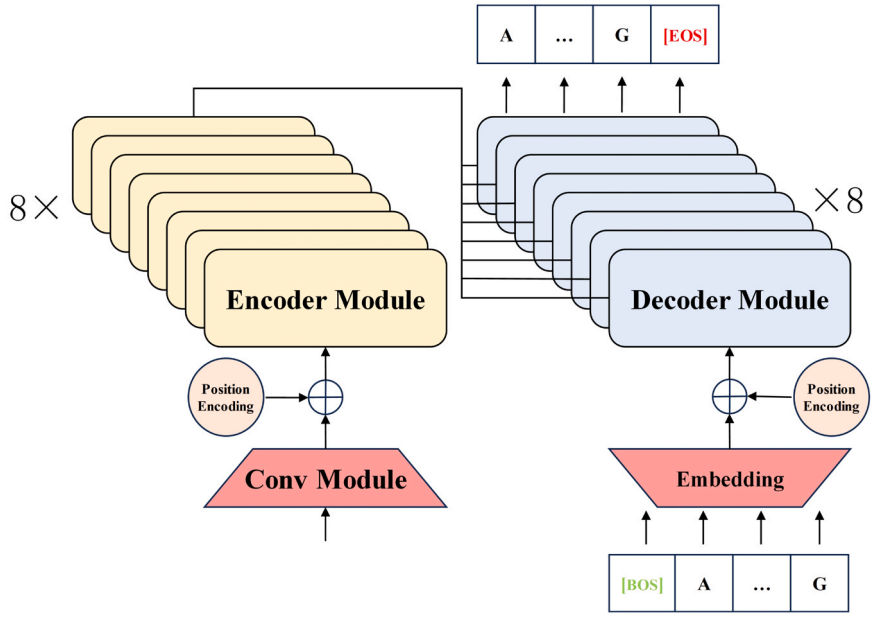

Fig. 3. Autoregressive Transformer-based model architecture for nanopore sequencing. The schematic illustrates the architecture of the autoregressive transformer model tailored for nanopore sequencing data. The model includes convolutional modules for feature extraction and down-sampling, an encoder composed of 8 layers for context modeling, and a decoder with 8 layers for sequence generation.

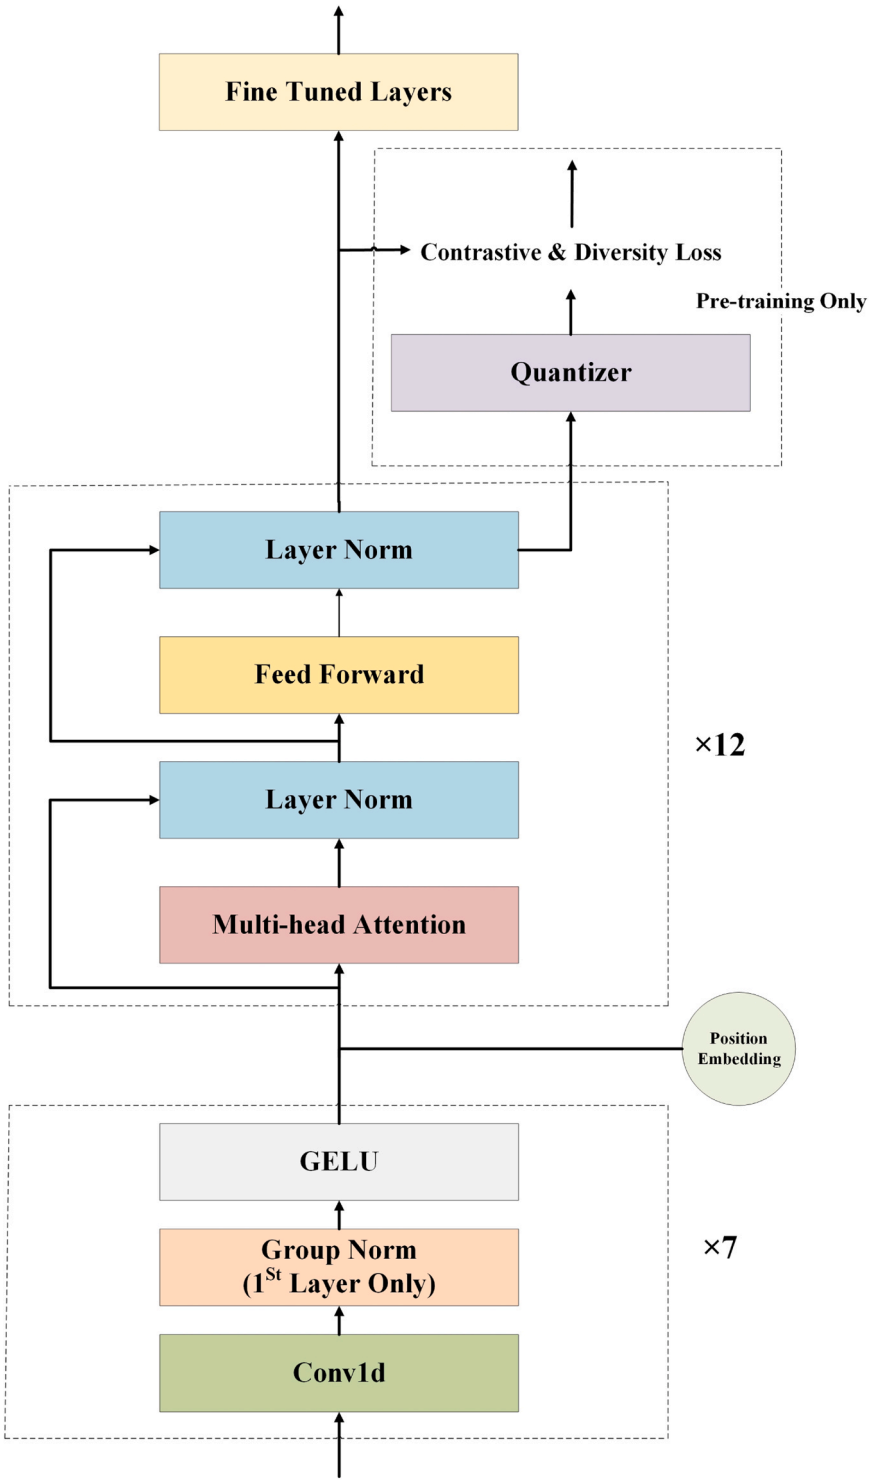

Fig. 4. Self-supervised large-scale model architecture in BaseNet. The schematic illustrates the self-supervised large-scale model architecture developed in BaseNet. The model comprises three key components: a feature extraction module, an encoder module for context modeling, and a quantization module for learning discrete common features through self-supervised pre-training.

（3）引入双层编码器后接线性投影层；
（4）采用三层编码器后接线性投影层；
（5）组合线性层、单层编码器及线性投影层；
（6）集成线性层、双层编码器及线性投影层；
（7）在模型顶部组合线性层、三层编码器及线性投影层。

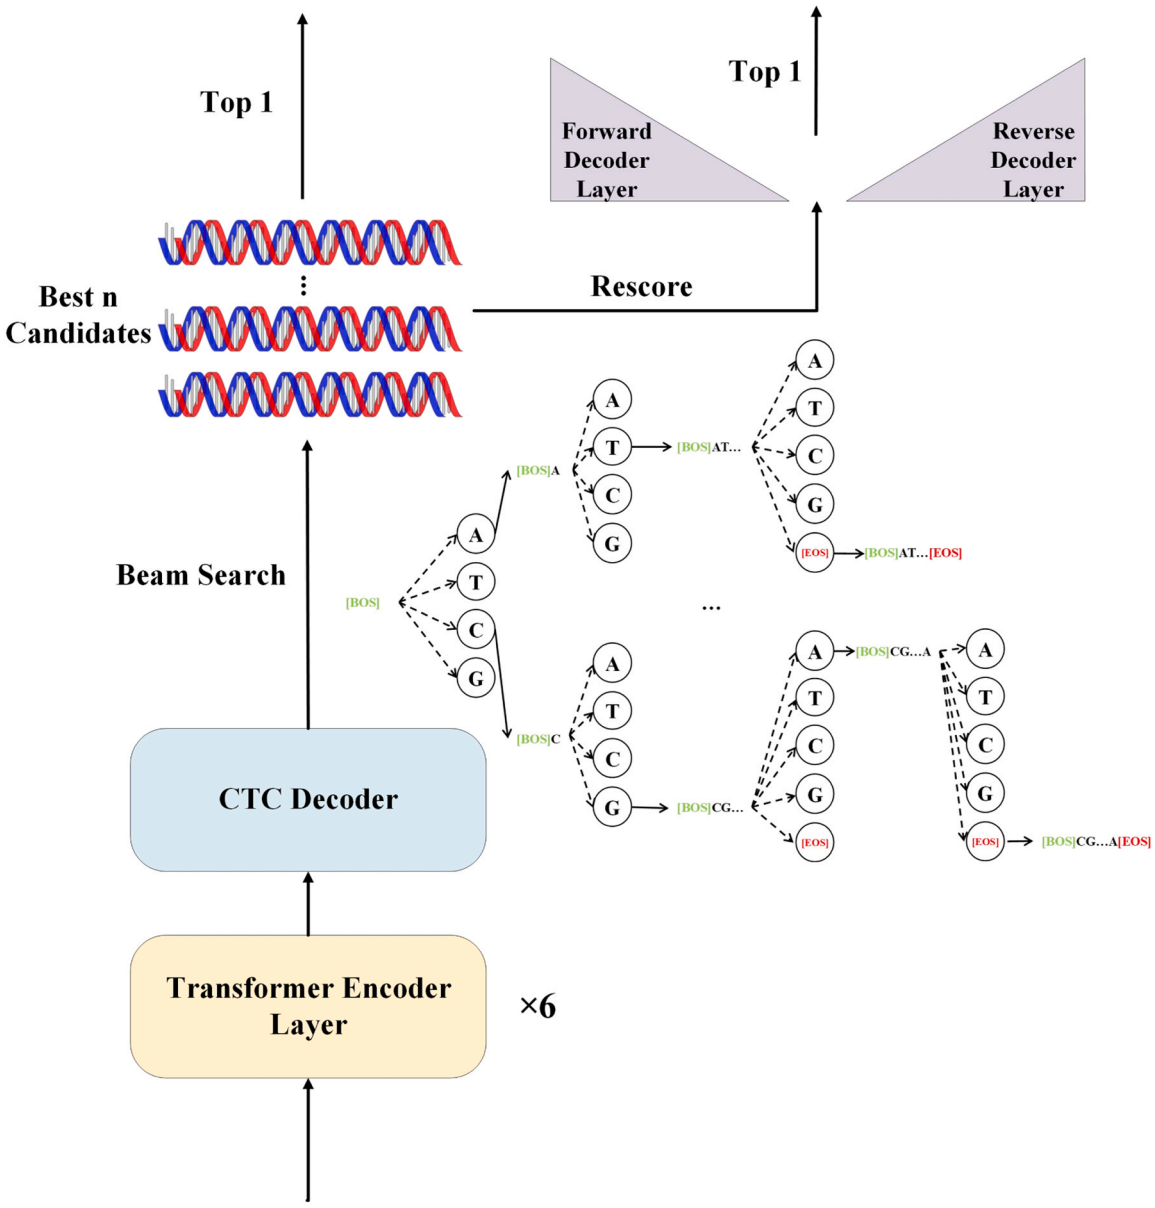

Fig. 5. BaseNet中的重评分与联合损失训练模型架构如图所示。该模型包含三个核心组件：
1）共享编码器：用于特征提取
2）CTC解码器：基于连接时序分类的输出层
3）注意力解码器：采用注意力机制的预测模块

$$L_{\text{joint}}(x,y) = \lambda L_{\text{CTC}}(x,y) + (1-\lambda) L_{\text{AED}}(x,y)$$

其中，x表示输出概率矩阵，y为标签，λ是介于0到1之间的超参数。

在重评分解码阶段，CTC解码器首先采用CTC前缀束搜索（CTC prefix beam search）生成n-best候选序列，随后注意力解码器对这些候选序列进行重评分，最终选择得分最高的序列作为解码输出。.

2.6. Paraformer

Paraformer模型包含以下核心组件（如图6所示）[28]：
1）编码器：用于生成隐藏表征
2）预测器：产生声学嵌入并预测序列长度
3）采样器：随机采样声学嵌入与目标嵌入以生成语义嵌入
4）解码器：基于语义嵌入和隐藏表征生成输出
然而，由于该模型计算需求庞大（单次训练周期耗时超过16小时），受限于计算资源，我们未实际训练此模型。现提供算法代码供参考和后续研究。

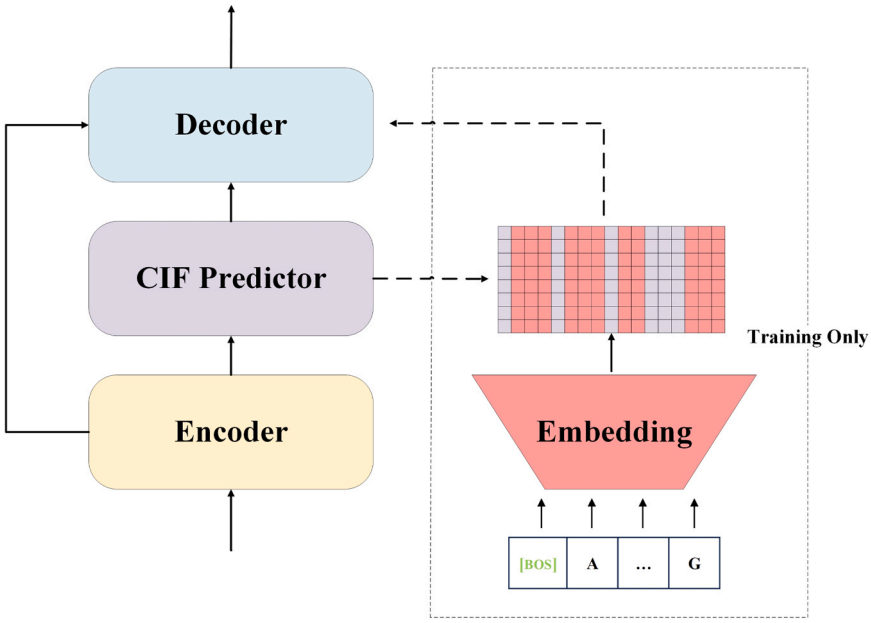

Fig. 6. BaseNet中的Paraformer架构如图所示，该模型采用以下核心组件构成：
1）表征编码器：通过多层网络结构生成隐藏表征
2）声学预测器：输出声学嵌入向量并预测序列长度
3）嵌入采样器：采用随机采样策略生成语义嵌入
4）序列解码器：基于语义嵌入和隐藏表征生成最终输出

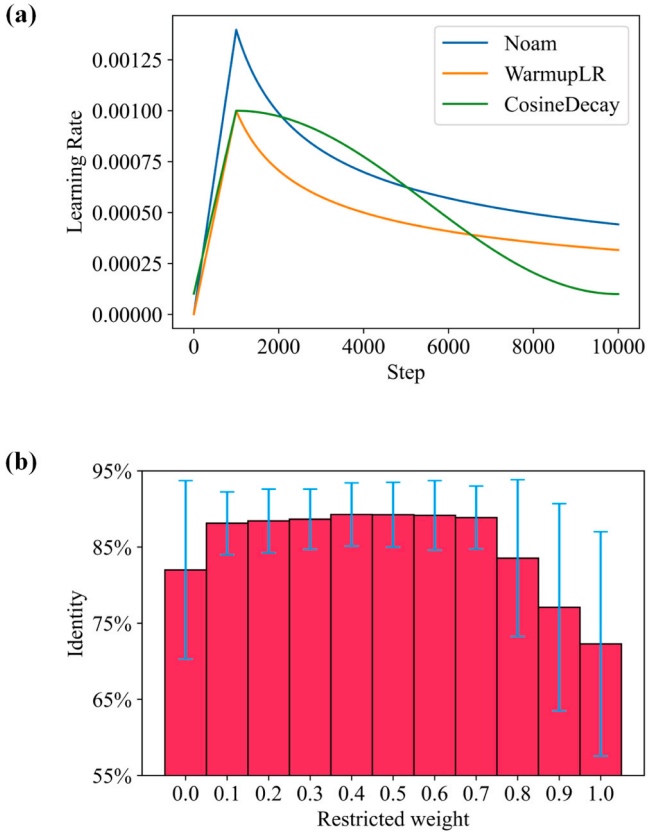

Fig. 7. BaseNet模型在不同学习率与约束权重下的性能表现分析（图示说明）：
(a) 学习率动态变化曲线（三种调度策略对比）：
• 余弦衰减调度器（CosineDecay）
• Noam优化调度器
• 预热学习率调度器（WarmupLR）
（参数配置：预热阶段1000训练步，总训练步数10,000步）
(b) 自回归Transformer模型的约束权重影响分析：
性能对比：当终止符约束权重w=0（无约束）或w≥0.8（强约束）时，模型预测性能出现显著下降
最优区间：约束权重w∈[0.1,0.7]范围内模型达到最佳性能表现